TRABALHO FINAL · ESTATÍSTICA AVANÇADA · CIn/UFPE

50,36% transportados

Spaceship Titanic

O que distingue quem foi transportado — e o que os dados permitem recomendar

8.693 passageiros	6 etapas analíticas	1 modelo de triagem

Gustavo Menezes · Helton Gomes · Luciana Almeida · Daniela Amaro · Renatta

Novembro de 2026 · Pós-Graduação em Deep Learning

RESUMO EXECUTIVO

A resposta em 30 segundos

Três números que organizam toda a apresentação

50,36%

dos passageiros foram transportados

4.378 de 8.693 — alvo equilibrado

81,47%

em criossono vs. 32,82% acordados

diferença de 48,65 p.p.

77,9%

de acurácia no teste

ROC-AUC 0,862 · F1 0,784

Criossono é o sinal mais forte. Origem e deck contam a mesma história por caminhos diferentes.

O gasto engana: 41,92% não gastaram nada e a mediana dos transportados é zero. O modelo apoia a triagem — não decide sozinho.

Leitura de 60 segundos

Metade da amostra foi transportada; o confinamento em criossono separa os grupos com a maior magnitude observada.

CONTEXTO

O incidente, o cliente e a pergunta

Por que esta análise existe

A nave atravessou uma anomalia espaço-temporal.

Metade dos 8.693 passageiros foi transportada para outra dimensão. Os registros de bordo sobreviveram, mas chegaram incompletos: quem estava a bordo, onde dormia, quanto consumiu e em que estado viajava.

A pergunta analítica

> “Quais características estão associadas ao desfecho, qual é a magnitude dessas associações e quão bem elas permitem prever quem foi transportado?”

Desenho observacional · sem afirmação causal

O cliente

Comando de Operações Espaciais e equipe de resgate

1 ENTENDER

Quais perfis estavam mais expostos ao teletransporte?

Apurar responsabilidades, comunicar famílias e revisar protocolos.

2 PREVER

Quais passageiros da base não rotulada foram transportados?

Priorizar busca e reconstrução de registros.

DADOS

De 14 para 22 variáveis, sem perder passageiros

Saneamento e engenharia de atributos

8.693 × 14
base bruta de treino

1,91%
células ausentes

24,01%
linhas incompletas

842
células recuperadas por regra

Pipeline em 10 etapas

1 Base bruta
14 colunas e 2.324 células ausentes

2 Regras de negócio
criossono e criança implicam gasto zero

3 Imputação
mediana e moda condicionais

4 Atributos
8 variáveis derivadas

5 Base analítica
8.693 × 22
0 ausentes

Decisões que protegem a análise

Nenhum outlier removido · nenhuma linha descartada · parâmetros estimados só no treino · impacto máximo da imputação: 0,77 p.p.

MÉTODO

Cinco perguntas, cinco camadas de evidência

O fio condutor da análise

01

DESCREVER

Quem são os passageiros e o que os distingue?

COMO

Proporções, medianas e figuras

02

ENTENDER A FORMA

As distribuições permitem os testes que queremos?

COMO

Shapiro-Wilk, Lilliefors e QQ-plots

03

TESTAR

As diferenças resistem à incerteza?

COMO

Qui-quadrado, Welch, ANOVA e pós-hoc

04

RELACIONAR E PREVER

O que se mantém no conjunto e com qual desempenho?

COMO

Correlações, ORs e regressão logística

05

RECOMENDAR

O que o cliente pode fazer com isso?

COMO

Triagem, priorização e cautela

Regra de ouro: nenhum número é citado sem a seção de origem.

ACHADO 01

O confinamento é o sinal mais forte

Criossono × transporte

81,47%

dos passageiros em criossono foram transportados

32,82% dos acordados

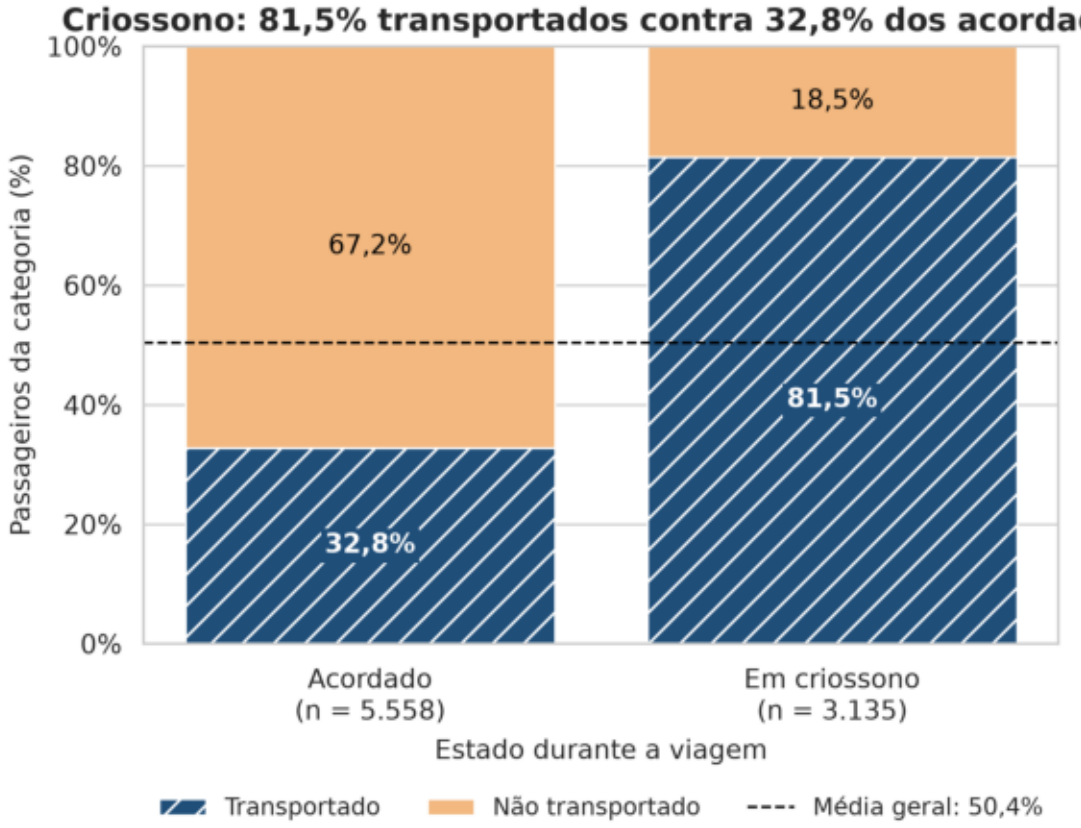
48,65 p.p.

de diferença — a maior do conjunto

V de Cramér = 0,467

associação muito forte

$\chi^2 = 1.897{,}71$ · $p < 0{,}001$



Taxa de transporte por estado de criossono (n = 8.693)

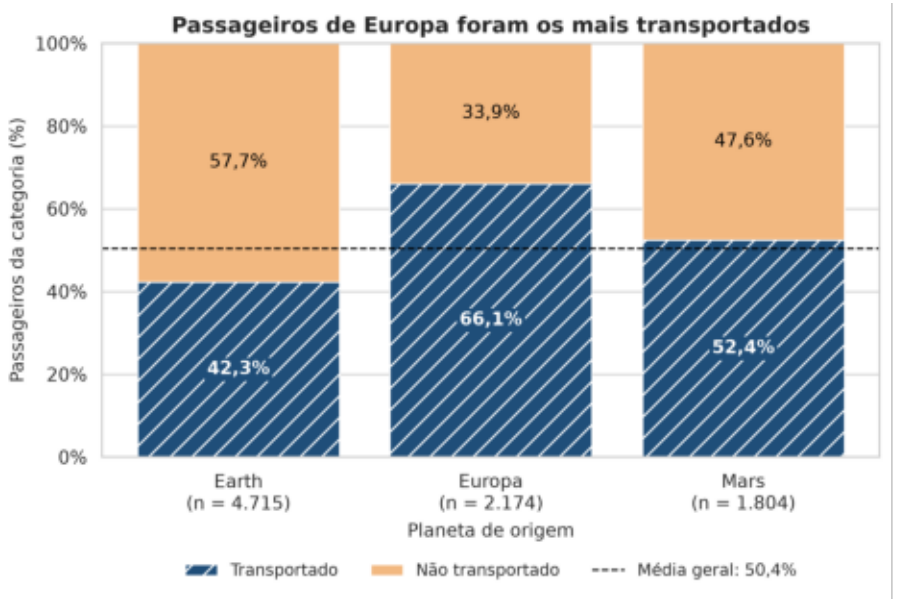
Fonte: Seção 2, figura 2 do relatório.

ACHADO 02

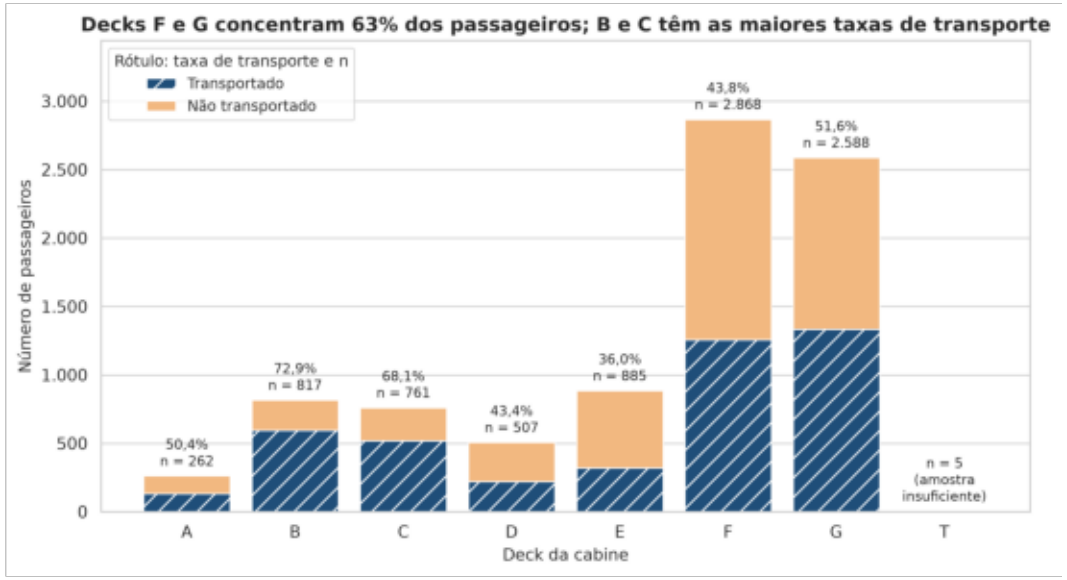
Origem e deck contam a mesma história

Taxas por planeta e por deck da cabine

Europa 66,05% | **Marte 52,44%** | **Terra 42,33%**



Taxa por planeta de origem



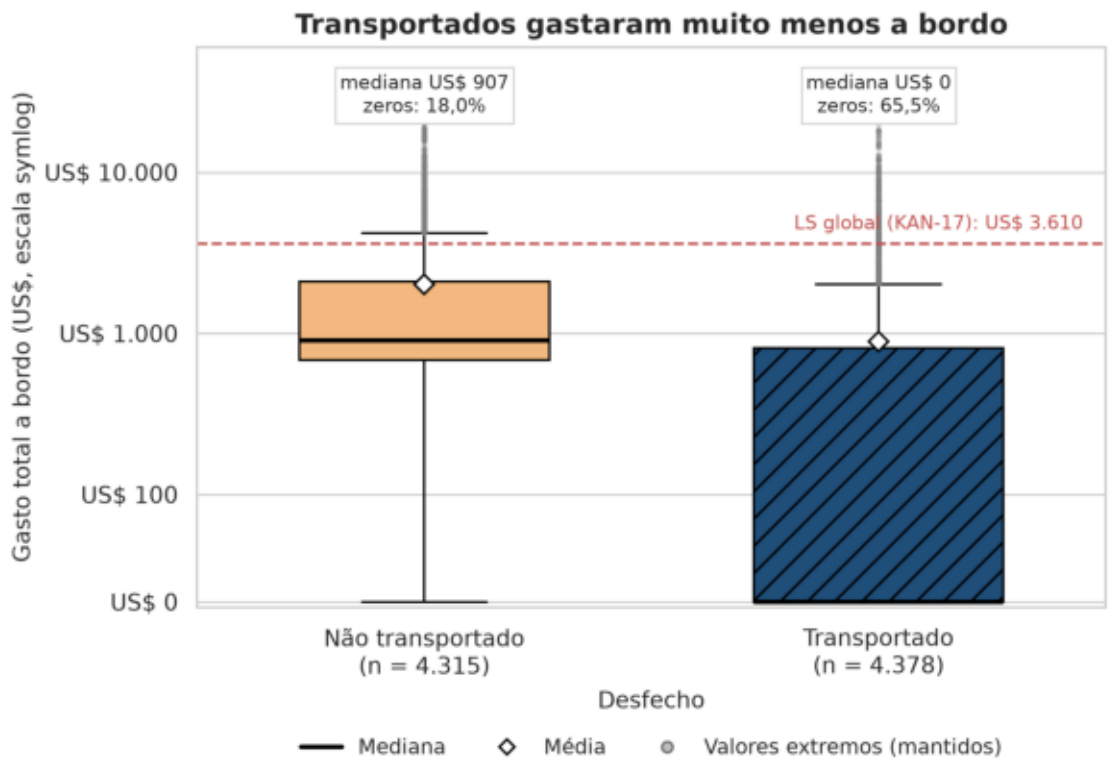
Passageiros e taxa por deck da cabine

72,6% dos europeus ocupam os decks B e C — os mesmos de maior taxa. Origem e localização física estão entrelaçadas.

ACHADO 03

O gasto é uma pista falsa — ou quase isso

Consumo, zero-inflação e o efeito do criossono



Gasto total por desfecho (escala symlog)

41,92%

não gastaram nada a bordo

Mediana de gasto

US$ 0,00 transportados

US$ 907,00 não transportados

Cuidado com a leitura causal

Quem está em criossono não consome. O gasto acompanha o confinamento, não protege contra ele.

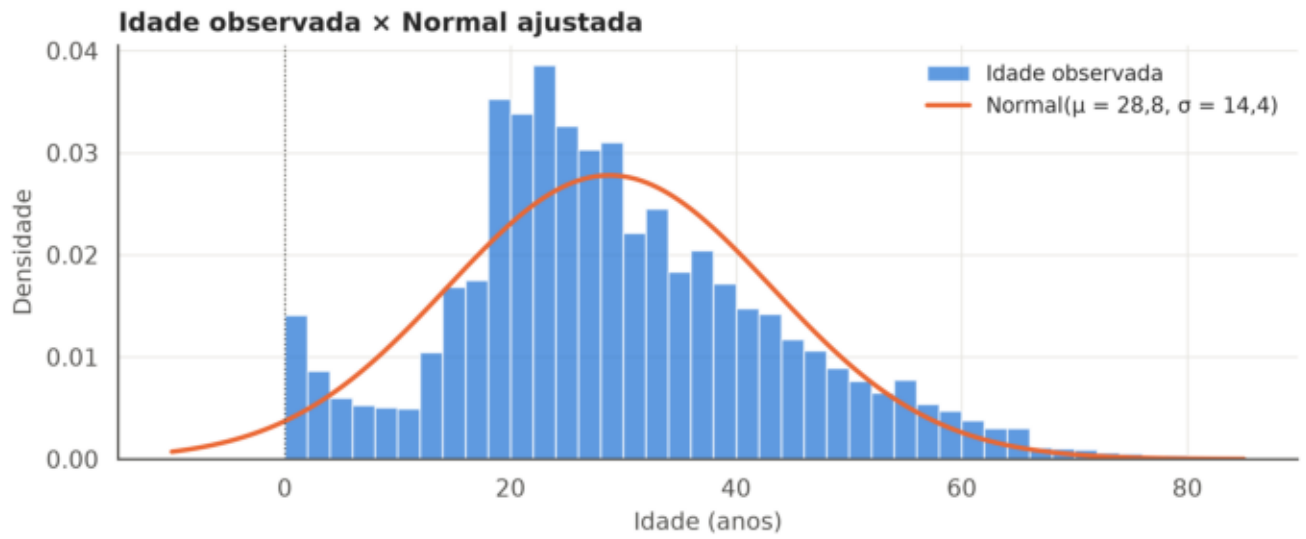
Assimetria 4,40 · 65,5% dos transportados com gasto zero

Fonte: Seções 2 e 4.

PROBABILIDADE

A forma da distribuição define o teste

Idade ≈ Normal; gasto positivo ≈ Log-Normal com caudas pesadas



Idade observada contra a Normal ajustada

LEITURA

O miolo está em idades mais baixas do que a Normal desloca; o pico em 0 são 178 bebês.

Age

W = 0,980 · D = 0,076

desvio pequeno: média e teste t são defensáveis

log1p(TotalSpend)

W = 0,891 · D = 0,126

assimetria cai de 4,40 para −0,19

mas a curtose 4,93 mantém as caudas pesadas

Implicação prática

Média para idade; mediana, proporção de zeros e testes robustos para gasto.

Shapiro-Wilk e Kolmogorov-Smirnov (Lilliefors), α = 0,05.

TESTES DE HIPÓTESES

As diferenças resistem ao teste

H0 de independência ou igualdade; α = 0,05

Relação	Teste	Estatística	p-valor	Tamanho do efeito	Leitura
Criossono × transporte	Qui-quadrado	χ^2 = 1.897,71	< 0,001	V = 0,467	muito forte
Planeta × transporte	Qui-quadrado	χ^2 = 338,82	< 0,001	V = 0,197	moderada
VIP × transporte	Qui-quadrado (Yates)	χ^2 = 12,07	0,0005	V = 0,037	desprezível
Gasto × transporte	t de Welch	t = 18,94	< 0,001	d = 0,407	moderado
Gasto × planeta	ANOVA de Welch	F = 407,57	< 0,001	η^2 = 0,171	grande

p-valor não é tamanho de efeito

VIP é significativo (p = 0,0005), mas V = 0,037: irrelevante na prática.

Pressupostos verificados

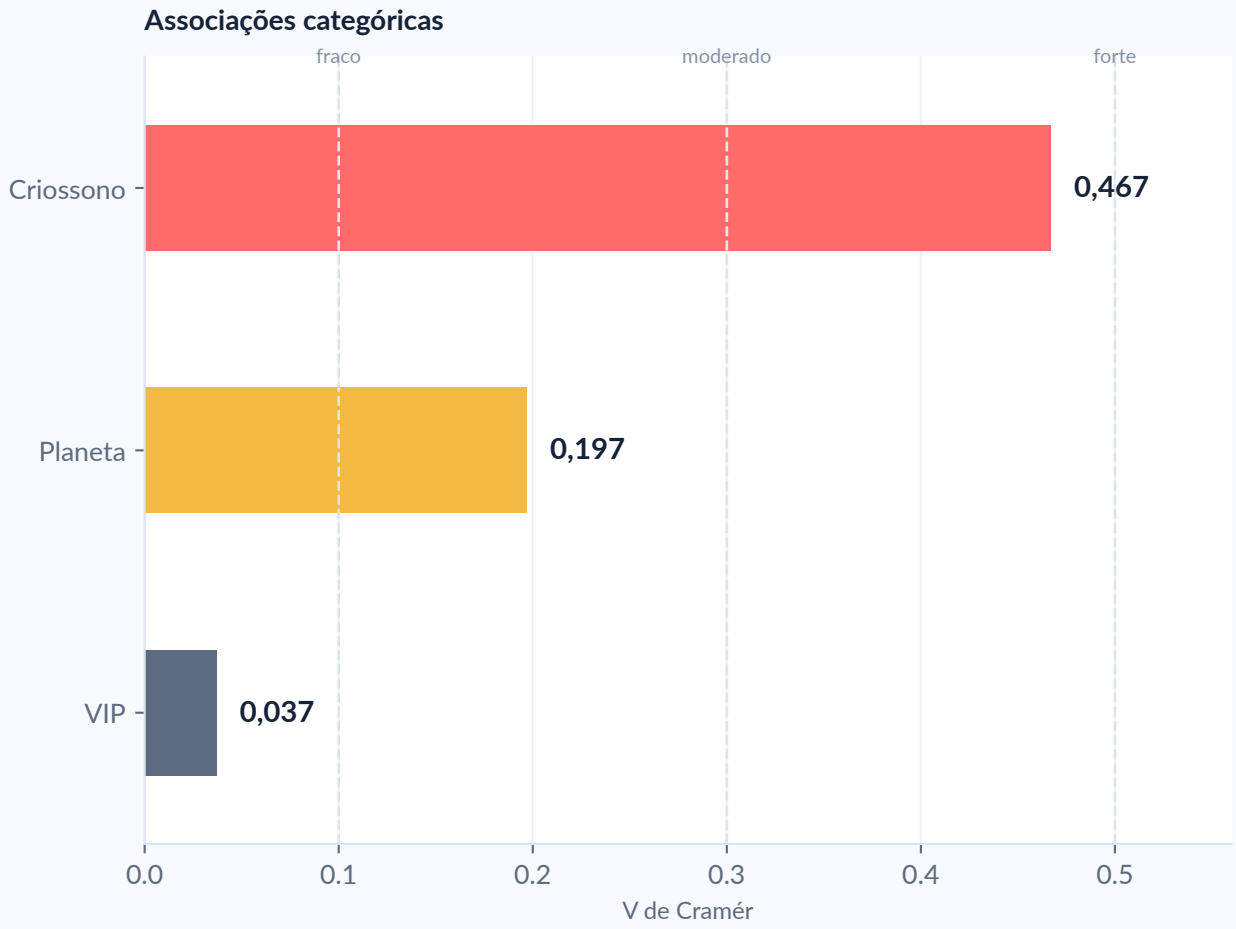
Levene rejeitou homocedasticidade: Welch e Games-Howell no lugar de Student e Tukey.

Fonte: Seção 4. Valores exatos e IC 95% no documento de conclusões.

LEITURA ESTATÍSTICA

Significância não é relevância

Tamanho do efeito: onde a diferença importa de verdade



d de Cohen = 0,407

Gasto × transporte: efeito moderado, com +US$ 1.120,74.

$\eta^2 = 0,171$

Origem explica 17,1% da variância do gasto: efeito grande.

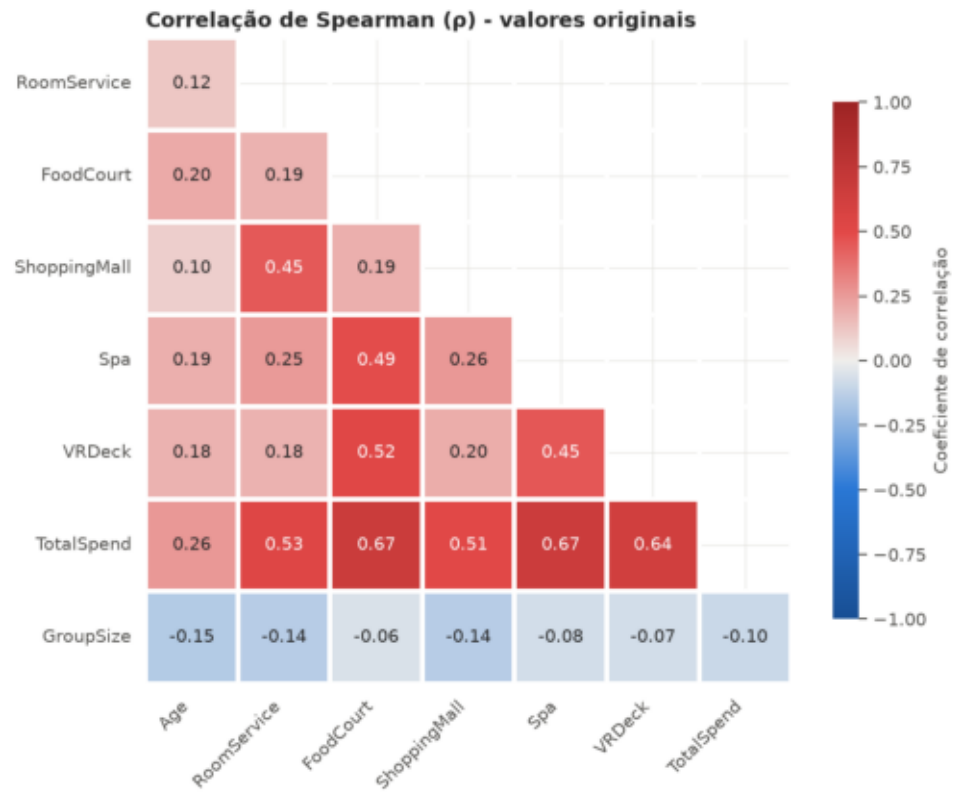
A lição do VIP

χ^2 significativo (p = 0,0005), V = 0,037. Com n grande, quase tudo fica significativo — o que importa é a magnitude.

CORRELAÇÃO

Quem consome um serviço tende a consumir outros

Pearson e Spearman lado a lado



Matriz de Spearman — 8 variáveis quantitativas

0,67 — **FoodCourt × TotalSpend**

a maior correlação — esperada, pois o total é a soma

0,52 — **FoodCourt × VRDeck**

uso combinado de serviços; Spearman supera Pearson

−0,18 — **Age × GroupSize**

a relação negativa mais forte, ainda assim fraca

Cuidado com multicolinearidade

HomePlanet e CabinDeck se sobrepõem: 72,6% dos europeus estão nos decks B/C e o deck G é 100% Terra. O VIF de Europa chega a 7,98 no treino.

Fonte: Seção 5, KAN-30.

MODELO PREDITIVO

Um apoio à triagem, não uma sentença

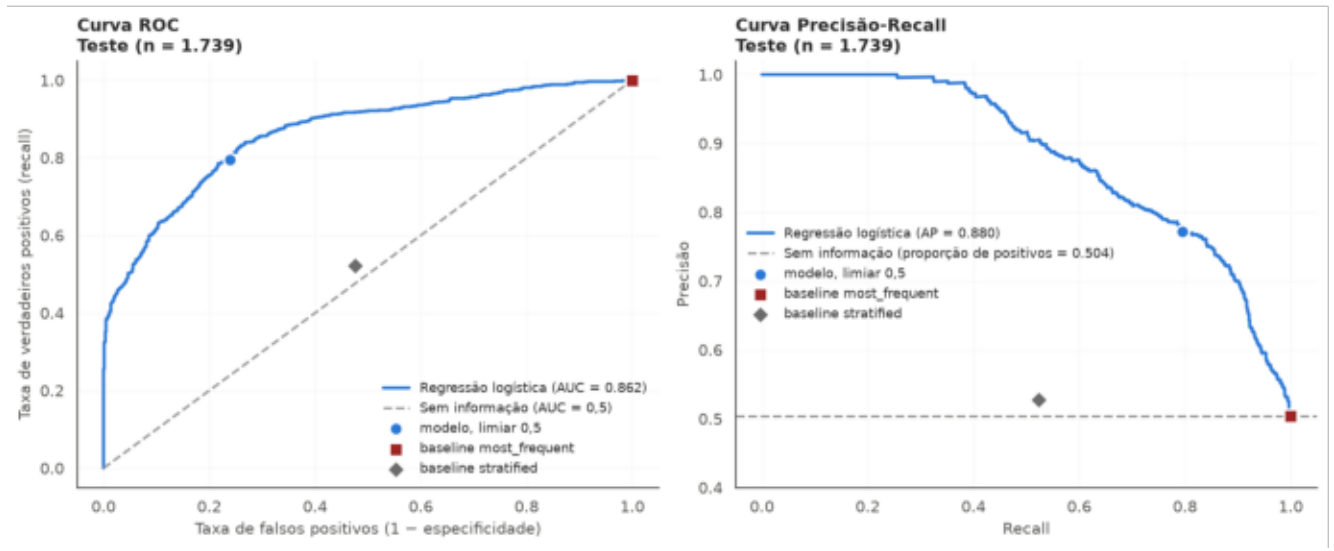
Regressão logística com limiar 0,5 fixado a priori

77,9%
acurácia

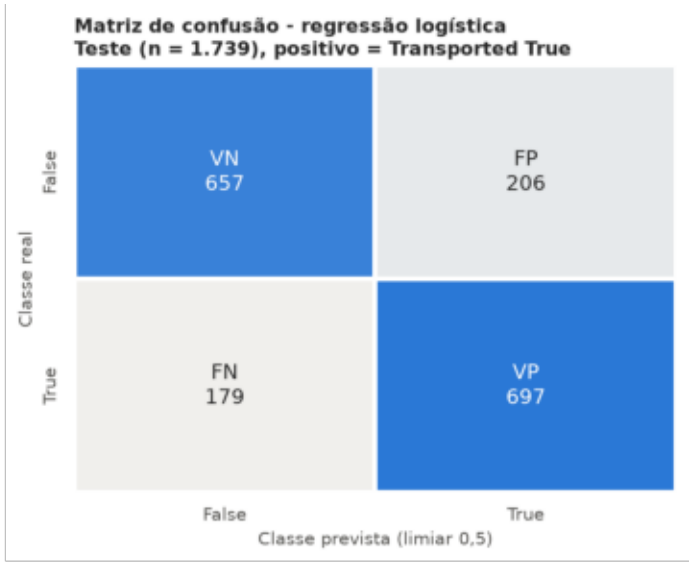
0,862
ROC-AUC

0,784
F1

+25,5 p.p.
sobre o baseline



Curvas ROC e Precision-Recall no conjunto de teste



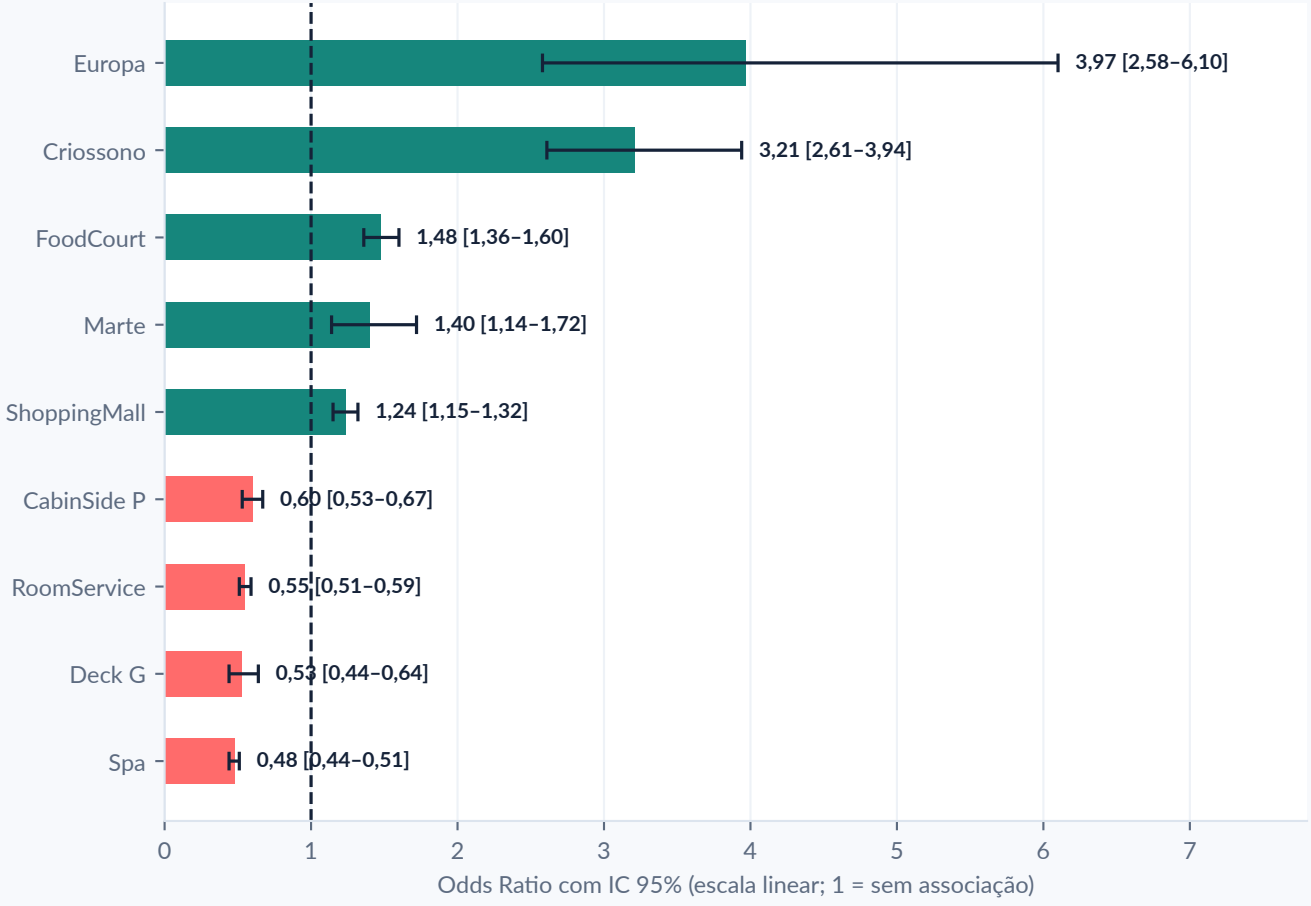
Matriz de confusão — 1.739 passageiros

Teste: 20% da base (1.739 passageiros), divisão estratificada, random_state = 42.

INTERPRETAÇÃO DO MODELO

O que o modelo aprendeu, ajustado pelas demais variáveis

Odds Ratios com IC 95% — associações, não causas



Referências: Terra, acordado, deck F, lado S; gastos por 1 DP de log1p.

Como ler

OR > 1 aumenta a chance de transporte; OR < 1 reduz.

Criossono: OR = 3,21

Chance 3,2× maior, já descontando gastos, origem, deck e demais variáveis.

Europa: OR = 3,97

Associação estimada dentro dos decks em que os planetas coexistem.

Pseudo-R^2 de McFadden = 0,311 no treino.

Fonte: Seção 5, KAN-33/34.

CONCLUSÕES

Três achados que respondem à pergunta

O que os dados sustentam — e com qual força

01

Criossono

81,47%

vs. 32,82% dos acordados

V = 0,467 · associação muito forte

02

Origem e deck

66,05%

Europa; Terra fica em 42,33%

72,6% dos europeus nos decks B/C

03

Gasto

41,92%

não gastaram nada

medianas: US0*eUS* 907

Todas as leituras são observacionais. Nenhum achado autoriza afirmar causalidade.

RECOMENDAÇÕES

O que o cliente pode fazer com isso

Quatro ações práticas, em ordem de prioridade

1 Priorizar a inspeção das cápsulas de criossono

POR QUÊ

É a associação mais forte e a mais acionável: 81,47% vs. 32,82%.

2 Investigar a diferença por origem, cruzada com deck e classe

POR QUÊ

Origem e localização física se sobrepõem; não usar origem isolada.

3 Abandonar o gasto como proxy de presença ou importância

POR QUÊ

41,92% não gastaram nada; usar cabine, grupo e criossono.

4 Usar o modelo como triagem, com revisão humana

POR QUÊ

Recall 0,796 e limiar 0,5 fixado a priori; recalibrar pelo custo do erro.

Próximo passo operacional: validar o modelo em uma divisão por grupo de viagem antes de qualquer uso real.

LIMITAÇÕES

O que este estudo não permite afirmar

Transparência metodológica para a banca

Limitações

- **Associação não é causa**
  O desenho é observacional e não isola mecanismos.
- **Divisão única de treino e teste**
  Sem intervalo de incerteza para as métricas.
- **Divisão por passageiro, não por grupo**
  Famílias podem aparecer dos dois lados; avaliação possivelmente otimista.
- **Imputação pela moda**
  2,1% a 2,5% das categóricas; impacto máximo de 0,77 p.p.
- **Multicolinearidade**
  HomePlanet_Europa com VIF de 7,98: coeficientes exigem cautela.

Próximos passos

1. **Validação por grupo de viagem**
   Reavaliar o modelo com GroupKFold ou divisão por família.
2. **Intervalos de confiança**
   Bootstrap para acurácia, ROC-AUC e F1.
3. **Recalibrar o limiar**
   Definir o custo relativo de falso positivo e falso negativo.
4. **Aprofundar origem × deck**
   Modelo hierárquico ou análise estratificada por deck.

A cautela não enfraquece o trabalho: define o que ele autoriza recomendar.

OBRIGADO

O que levamos desta análise

Metade da nave foi transportada. O criossono é o sinal mais forte, a origem e o deck contam a mesma história, e o gasto não é um bom atalho. O modelo ajuda a triar — não substitui o juízo humano.

81,47%
criossono

66,05%
Europa

77,9%
acurácia

Perguntas?

Gustavo Menezes · Helton Gomes · Luciana Almeida · Daniela Amaro · Renatta

CIn/UFPE · 2026