Roteiro de Nivelamento & Apresentações Cruzadas

Reunião 2 · 31/10/2026 · Domínio Integral do Projeto e Eliminação de Silos

1. VISÃO DE NEGÓCIO & ALINHAMENTO ESTRATÉGICO

- **Objetivo Acadêmico**
  Integrar o conteúdo de Estatística Avançada para IA de forma aplicada no Spaceship Titanic.
- **Eliminação de Silos**
  Garantir que todos os 5 membros dominem 100% da metodologia, dados e conclusões de todas as trilhas.
- **Problema Analítico**
  Determinar fatores sociodemográficos, espaciais e de consumo associados ao transporte (Transported).
- **Critérios de Avaliação**
  Observância dos pesos: 30% Qualidade Técnica, 50% Clareza/Objetividade e 20% Reprodutibilidade.
- **Postura com a Banca**
  Nenhum número citado sem seção de origem. Clareza sobre a distinção entre associação e causalidade.

2. DINÂMICA DE VALIDAÇÃO CRUZADA (APRESENTAÇÕES ESPELHO)

- **Formato da Apresentação**
  O autor resume o capítulo em até 5 min nos 4 eixos: Pergunta, Método, Números e Limitações.
- **Papel do Revisor Dedicado**
  O revisor reexplica o capítulo do colega com suas próprias palavras perante o grupo.
- **Par 1 (Capítulo 1)**
  Preparação de Dados: Gustavo Menezes apresenta | Helton reexplica e valida.
- **Par 2 (Capítulo 2)**
  Estatística Descritiva: Helton apresenta | Luciana reexplica e valida.
- **Par 3 (Capítulo 3)**
  Probabilidade e Distribuições: Luciana apresenta | Daniela reexplica e valida.
- **Par 4 (Capítulo 4)**
  Testes de Hipóteses e ANOVA: Daniela apresenta | Renatta reexplica e valida.
- **Par 5 (Capítulo 5)**
  Correlação e Modelagem Preditiva: Renatta apresenta | Gustavo Menezes reexplica e valida.

3. COMPROMISSO DA EQUIPE E PRÉ-REQUISITOS DE HOMOLOGAÇÃO

- **Quórum Pleno**
  Participação confirmada dos 5 integrantes: Gustavo, Helton, Luciana, Daniela e Renatta.
- **Reprodutibilidade Estrita**
  Fixação de seed(42), ausência de caminhos absolutos e execução Restart & Run All limpa.
- **Critério de Aprovação**
  Reunião concluída apenas com validação e aceite consensual dos 5 capítulos.

Capítulo 1 · Preparação, Limpeza e Engenharia de Atributos

Apresentador: Gustavo Menezes Gonçalves | Revisor Dedicado: Helton

1. PERGUNTA CENTRAL & CONTEXTO DOS DADOS

▸ **Pergunta**

Como transformar uma base com nulos e texto em formato analítico sem criar distorções ou data leakage?

▸ **Escopo Amostral**

8.693 passageiros da nave com 14 colunas brutas heterogêneas.

2. METODOLOGIA & DECISÕES TÉCNICAS

▸ **Imputação Controlada**

Moda para categóricas e mediana para numéricas, testando sensibilidade populacional.

▸ **Engenharia de Variáveis**

Extração de GroupId, GroupSize e IsAlone de PassengerId; Deck, CabinNum e Side de Cabin.

▸ **Métricas de Consumo**

Soma vetorial TotalSpend das 5 comodidades pagas e criação da flag binária HasSpended.

▸ **Governança de Outliers**

Nenhum passageiro extremo de consumo descartado; preservação da integridade da tripulação.

3. NÚMEROS CANÔNICOS & EVIDÊNCIAS EMPÍRICAS

▸ **Integridade Final**

8.693 registros limpos com 22 colunas enriquecidas e exatamente zero nulos.

▸ **Teste de Sensibilidade**

Desvio máximo entre proporções pré e pós-imputação foi de apenas 0,64 ponto percentual.

▸ **Consistência Física**

100% dos passageiros em criossono possuem despesa estritamente igual a US$ 0,00.

▸ **Viajantes Solitários**

55,30% dos passageiros viajavam desacompanhados (IsAlone = True).

4. DESAFIO PARA O REVISOR DEDICADO (HELTON) & LIMITAÇÕES

▸ **Pergunta de Desafio**

Por que não descartamos simplesmente as linhas que possuíam valores ausentes?

▸ **Resposta do Revisor**

O descarte eliminaria ~2.000 passageiros (quase 25% da base), introduzindo viés de seleção grave.

▸ **Ponto de Cautela**

Toda imputação deve aprender estritamente com os dados de treino para evitar data leakage.

Capítulo 2 · Estatística Descritiva e Análise Visual

Apresentador: Helton | Revisor Dedicado: Luciana

1. PERGUNTA CENTRAL & CONTEXTO DESCRITIVO

▸ **Pergunta**
Quais são os perfis sociodemográficos e padrões de consumo associados ao transporte?

▸ **Escopo Analítico**
Análise univariada, bivariada e detecção de assimetrias estruturais nas despesas.

2. METODOLOGIA & TÉCNICAS EXPLORATÓRIAS

▸ **Medidas de Resumo**
Cálculo de tendência central, dispersão, IQR, assimetria (skewness) e curtose.

▸ **Tabelas Cruzadas**
Estratificação das taxas de transporte por planeta de origem, convés e criossono.

▸ **Detecção de Zero-Inflação**
Identificação de massa de probabilidade pontual em despesas nulas.

▸ **Visualização Rigorosa**
Histogramas com densidade KDE, boxplots comparativos e barras estratificadas.

3. NÚMEROS CANÔNICOS & EVIDÊNCIAS EMPÍRICAS

▸ **Taxa Global de Transporte**
50,36% dos passageiros transportados (4.378 de 8.693).

▸ **Impacto do Criossono**
81,47% em criossono foram transportados contra apenas 32,82% dos acordados (+48,65 p.p.).

▸ **Origem Planetária**
Europa 66,05% (1.439/2.179) | Marte 52,44% (930/1.773) | Terra 42,33% (1.987/4.693).

▸ **Zero-Inflação em Despesas**
41,92% com gasto nulo. Mediana dos transportados US$ 0 vs US$ 907 dos não-transportados.

▸ **Assimetria de Gastos**
Assimetria severa de 4,40; média global de US$ 1.480 distorcida pela cauda superior.

4. DESAFIO PARA A REVISORA DEDICADA (LUCIANA) & LIMITAÇÕES

▸ **Pergunta de Desafio**
Por que é proibido usar a média aritmética para comparar os gastos entre os grupos?

▸ **Resposta da Revisora**
Porque a presença de 41,92% de zeros e cauda pesada faz a média mentir; a mediana é a medida honesta.

▸ **Padrão nos Conveses**
Decks superiores B e C abrigam passageiros de Europa e têm transporte superior a 70%.

Capítulo 3 · Teoria de Probabilidade e Distribuições

Apresentador: Luciana | Revisor Dedicado: Daniela

1. PERGUNTA CENTRAL & JUSTIFICATIVA TEÓRICA

▸ **Pergunta**

As variáveis quantitativas (Age e TotalSpend) aderem a distribuições teóricas Normal ou Log-Normal?

▸ **Relevância Prática**

A forma das distribuições dita a escolha entre testes paramétricos clássicos ou métodos robustos.

2. METODOLOGIA & TRÍADE PROBATÓRIA

▸ **Inspeção de Densidade**

Gráficos de densidade empírica vs gaussiana e Quantile-Quantile Plots (QQ-plots).

▸ **Testes Formais**

Aplicação combinada de Shapiro-Wilk (quantis amostrais) e Kolmogorov-Smirnov (distribuição acumulada).

▸ **Transformações**

Investigação da transformação logarítmica log(1 + x) para estabilização de variância.

▸ **Orientação Inferencial**

Avaliação de premissas de homocedasticidade e normalidade residual.

3. NÚMEROS CANÔNICOS & EVIDÊNCIAS EMPÍRICAS

▸ **Idade (Age)**

Shapiro-Wilk $W = 0{,}980$ ($p < 10^{-15}$); Kolmogorov-Smirnov $D = 0{,}076$.

▸ **Diagnóstico de Idade**

Comportamento aproximadamente normal no corpo central, com leve truncamento em crianças e idosos.

▸ **Gastos (log1p TotalSpend)**

Shapiro-Wilk $W = 0{,}891$ ($p < 10^{-15}$); Kolmogorov-Smirnov $D = 0{,}126$; curtose de 4,93.

▸ **Diagnóstico de Gastos**

Distribuição bimodal mista (massa pontual de zeros de 41,92% + cauda pesada assimétrica).

▸ **Implicação Direta**

Rejeição categórica de testes t de Student clássicos e de ANOVA clássica de Fisher.

4. DESAFIO PARA A REVISORA DEDICADA (DANIELA) & LIMITAÇÕES

▸ **Pergunta de Desafio**

Se o p-valor de Shapiro-Wilk rejeita a normalidade de Age, por que a consideramos aproximadamente normal?

▸ **Resposta da Revisora**

Com n=8.693, o teste tem potência máxima e rejeita desvios ínfimos; W=0,980 prova forte aderência prática.

▸ **Ponto de Cautela**

TotalSpend não pode ser tratada como Log-Normal pura por causa da concentração em zero.

Capítulo 4 · Testes de Hipóteses, Comparações e ANOVA

Apresentador: Daniela | Revisor Dedicado: Renatta

1. PERGUNTA CENTRAL & FORMULAÇÃO INFERENCIAL

▸ **Pergunta**

As discrepâncias de transporte e consumo são estatisticamente significativas ou mero ruído amostral?

▸ **Tamanho de Efeito**

Determinar a magnitude prática das associações além da mera significância estatística (p-valor).

2. METODOLOGIA ESTATÍSTICA RIGOROSA

▸ **Independência Categórica**

Testes Qui-Quadrado de Pearson (χ^2) acompanhados do coeficiente V de Cramér.

▸ **Comparação de Duas Médias**

Teste t de Welch para variâncias heterogêneas e tamanho de efeito d de Cohen.

▸ **Comparação de Três Grupos**

ANOVA de Welch (F) após Levene acusar heterocedasticidade severa (razão de variâncias > 37x).

▸ **Pós-hoc Robusto**

Teste pareado de Games-Howell para controle de erro Tipo I sob variâncias desiguais.

3. NÚMEROS CANÔNICOS & EVIDÊNCIAS EMPÍRICAS

▸ **Associação Criossono**

$\chi^2 = 1.897{,}71$ (gl = 1, $p < 10^{-15}$); V de Cramér = 0,467 (associação extremamente forte).

▸ **Associação Planeta**

$\chi^2 = 338{,}82$ (gl = 2, $p < 10^{-15}$); V de Cramér = 0,197 (associação moderada a substancial).

▸ **Associação Convés**

$\chi^2 = 389{,}01$ (gl = 7, $p < 10^{-15}$); V de Cramér = 0,212.

▸ **Teste t de Welch**

$t = 18{,}94$ ($p < 10^{-15}$); d de Cohen = 0,407 (não-transportados consumiram significativamente mais).

▸ **ANOVA de Welch (Origem)**

$F = 407{,}57$ ($p < 10^{-15}$); $\eta^2 = 0{,}171$ (17,1% da variação de consumo explicada pelo planeta natal).

▸ **Pós-hoc Games-Howell**

Europa gasta expressivamente mais que Terra e Marte ($p < 10^{-6}$ para todas as comparações).

4. DESAFIO PARA A REVISORA DEDICADA (RENATTA) & LIMITAÇÕES

▸ **Pergunta de Desafio**

Por que não adotar a ANOVA clássica de Fisher para comparar os gastos dos planetas?

▸ **Resposta da Revisora**

A razão de variâncias passa de 37x; a ANOVA clássica inflaria os erros falso-positivos (Tipo I).

▸ **Magnitude Prática**

O V de Cramér comprova que Criossono tem associação mais de duas vezes superior a Planeta.

Capítulo 5 · Correlação, Regressões e Modelo Preditivo

Apresentador: Renatta | Revisor Dedicado: Gustavo Menezes Gonçalves

1. PERGUNTA CENTRAL & MODELAGEM ESTATÍSTICA

▸ **Pergunta**
Como as variáveis se correlacionam e qual o poder de um modelo logístico interpretável para triagem?

▸ **Compromisso Ético**
Definir os limites de aplicabilidade preditiva: apoio à triagem vs decisão automática.

2. METODOLOGIA DE MODELAGEM & VALIDAÇÃO

▸ **Correlação Não-Linear**
Matriz de Spearman avaliando associações monotônicas sem exigir normalidade.

▸ **Regressão Múltipla OLS**
Ajuste linear em log1p(TotalSpend) para identificar determinantes socioeconômicos de consumo.

▸ **Regressão Logística**
Divisão 80/20 estratificada (seed 42), padronização e One-Hot Encoding.

▸ **Métricas de Desempenho**
Acurácia, ROC-AUC, Precision-Recall AUC, F1-Score, Sensibilidade e Especificidade.

3. NÚMEROS CANÔNICOS & EVIDÊNCIAS EMPÍRICAS

▸ **Regressão Linear Gastos**
$R^2 = 0,314$ (Idade, conveses superiores B/C e Europa explicam 31,4% do gasto a bordo).

▸ **Acurácia do Modelo**
77,9% no conjunto de teste (+27,5 p.p. superior à regra ingênua de 50,36%).

▸ **Capacidade Discriminativa**
ROC-AUC = 0,862 | Precision-Recall AUC = 0,880.

▸ **Equilíbrio de Classes**
Precisão = 77,2% | Sensibilidade (Recall) = 79,6% | F1-Score = 78,4% | Especificidade = 76,1%.

▸ **Odds Ratios**
CryoSleep multiplica em > 8,5x as chances de transporte; gastos em Spa/VRDeck reduzem a chance.

4. DESAFIO PARA O REVISOR DEDICADO (GUSTAVO) & LIMITAÇÕES

▸ **Pergunta de Desafio**
Este modelo logístico pode ser utilizado para automação de decisões de resgate?

▸ **Resposta do Revisor**
Não. A acurácia de 77,9% gera 22% de erros; ele serve para priorização e triagem investigativa.

▸ **Ponto de Cautela**
O limiar de decisão foi fixado a priori em 0,5 para evitar data snooping e otimização espúria.

Síntese Executiva & Tabela de Bolso de Números Canônicos

Compêndio Rápido de Fatos e Números Inquestionáveis para a Apresentação

1. TABELA DE BOLSO: NÚMEROS CANÔNICOS INQUESTIONÁVEIS

Amostra Total	8.693 passageiros (sem perda de registros; 22 colunas após engenharia de dados).
Taxa Global Transporte	50,36% (4.378 transportados / 4.315 não-transportados) — classes equilibradas.
Efeito Criossono	81,47% em estase vs 32,82% acordados (χ^2 = 1.897,71; V de Cramér = 0,467).
Origem Planetária	Europa 66,05% | Marte 52,44% | Terra 42,33% (χ^2 = 338,82; V de Cramér = 0,197).
Despesas Nulas	41,92% da tripulação com US$ 0 (mediana transportados US$ 0; não-transp. US$ 907).
Aderência Idade	Shapiro-Wilk W = 0,980 (KS D = 0,076) — aproximadamente normal no corpo central.
Despesas por Origem	ANOVA de Welch F = 407,57 (η^2 = 0,171); pós-hoc Games-Howell $p < 10^{-6}$ para todos os pares.
Regressão Logística	Acurácia 77,9% (+27,5 p.p. sobre baseline); ROC-AUC 0,862; F1-Score 78,4%.

2. AS TRÊS DIRETRIZES CENTRAIS PARA O TOMADOR DE DECISÃO

▸ **1. Foco em Criossono**
Priorizar auditoria técnica das cápsulas de estase; o isolamento físico ou energético é crítico.

▸ **2. Estrutura e Origem**
Investigar conveses superiores (B e C) onde Europa concentra alta taxa de transporte.

▸ **3. Desmistificar Gasto**
Gasto alto não protege passageiros; reflete apenas circulação ativa em decks inferiores.

▸ **Cautela Metodológica**
Estudo estritamente observacional: correlação sólida não constitui nexo de causa direta.

Homologação Final, Checklist de Domínio & Assinatura da Ata

Registro Oficial de Conclusão da Reunião 2 e Liberação para o Fechamento do Projeto

1. CHECKLIST DE DOMÍNIO ANALÍTICO INDIVIDUAL DOS 5 INTEGRANTES

Gustavo Menezes	Demonstrou domínio de preparação, imputações sem bias e modelo logístico preditivo.
Helton	Demonstrou domínio de estatística descritiva, zero-inflação e preparação de dados.
Luciana	Demonstrou domínio de distribuições, testes de aderência e análise exploratória visual.
Daniela	Demonstrou domínio de testes de hipóteses, ANOVA de Welch e teoria de probabilidade.
Renatta	Demonstrou domínio de correlação de Spearman, regressões e testes inferenciais.

2. DELIBERAÇÃO COLETIVA E AUTORIZAÇÃO DE PRÓXIMOS PASSOS

▸ **Parecer Técnico**
Os cinco membros da equipe foram aprovados com louvor na dinâmica de validação cruzada.

▸ **Eliminação de Silos**
Constatada capacidade de defesa integral de qualquer capítulo por qualquer membro perante a banca.

▸ **Autorização KAN-37**
Liberada a consolidação oficial dos notebooks para geração de 00_projeto_final_estatistica.ipynb.

▸ **Autorização Relatório**
Liberada a finalização da redação do relatório técnico final (KAN-39 a KAN-42).

3. ASSINATURA FORMAL DA ATA DA REUNIÃO 2

▸ **Data e Local**
Recife/PE, 31 de outubro de 2026 — Sessão Virtual Síncrona.

▸ **Assinaturas**
Gustavo Menezes Gonçalves (Coordenação) · Helton · Luciana · Daniela · Renatta.